Reconnaissance Automatisée de Variétés de Haricots Secs par Apprentissage Supervisé

Étude Comparative de Cinq Architectures sur le Dataset UCI Dry Bean

Équipe Projet Machine Learning (DSE) :

Youssef **FATIMI** Hamza **BALLA** Mohamed Yahya **SAFADI** Ayoub **ELHANAFI**

Sous la direction académique de : **Pr. Saidi**

Année Universitaire 2026–2027



Institut National de Statistique et d'Économie Appliquée (INSEA)

1. Contexte Métier & Problématique Scientifique

Contexte Métier & Défi Industriel

- Le contrôle de pureté variétale des légumineuses est un enjeu agronomique et commercial majeur.
- Le tri manuel traditionnel est subjectif, lent et coûteux.
- **Objectif :** Automatiser la reconnaissance des 7 variétés par apprentissage supervisé **sans traiter directement les images**.

Questions Centrales du Cahier des Charges

1. **Quels modèles** distinguent le mieux les sept variétés ?
2. **Quelles classes** restent les plus difficiles à reconnaître ?

Périmètre des Cinq Modèles Étudiés

- **Régression Logistique Multiclasse** (Softmax L_2)
- **K-Plus Proches Voisins** (KNN Géométrique)
- **Arbre de Décision** (CART)
- **Forêt Aléatoire** (Random Forest par bagging)
- **Support Vector Machines** (SVM Linéaire & RBF)

Approche TDD & Rigueur Scientifique

Validation empirique systématique : chaque hypothèse théorique est confirmée par des mesures quantifiées sur le jeu de test scellé.

2. Description du Corpus UCI Dry Bean & Déséquilibre

Corpus UCI Dry Bean & Métrique Reine

$N = \mathbf{13\,611}$ grains · 16 descripteurs · Asymétrie de 1 à 6.8.
Le **F1-score Macro** $F_{1,\text{macro}} = \frac{1}{K}\sum F_{1,k}$ est le critère cardinal.

Répartition des 7 Variétés dans le Corpus

Variété	Code	Effectif	Proportion
Dermason	DERMASON	3 546	26.05 %
Sira	SIRA	2 636	19.37 %
Seker	SEKER	2 027	14.89 %
Horoz	HOROZ	1 928	14.16 %
Cali	CALI	1 630	11.98 %
Barbunya	BARBUNYA	1 322	9.71 %
Bombay	BOMBAY	522	3.84 %
Total	**7 classes**	**13 611**	**100.00 %**

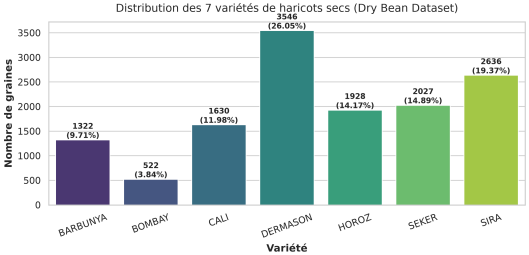


Figure 1 : *Distribution des effectifs par variété de haricot*

3. Distributions Morphologiques & Invariants Physiques

Les 4 Invariants Physiques Fondamentaux

1. **Bombay (Géant) :** Aire médiane $\approx 173\,000$ px^2 (vs $< 70\,000$ px^2 pour les autres). Séparabilité quasi linéaire immédiate.
2. **Horoz (Allongé) :** Ratio d'aspect (> 2.1) et excentricité maximaux : silhouette cylindrique nette.
3. **Seker (Sphérique) :** Compacité et circularité maximales (≈ 0.94).
4. **Dermason / Sira (Piège) :** Tailles et formes presque confondues : **foyer d'erreur majeur attendu**.

Multicolinéarité Dimensionnelle

Corrélations $r \geq 0.98$ entre `Area`, `Perimeter` et `ConvexArea` $\rightarrow$ impose une régularisation de crête (L_2).

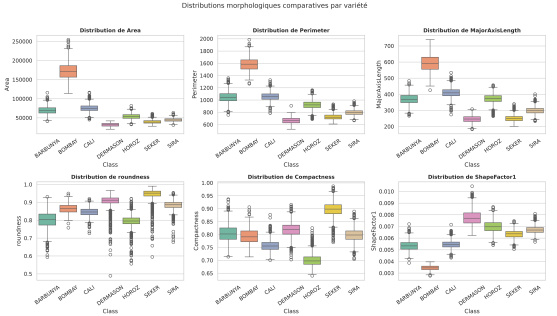


Figure 2 : *Distributions comparatives des descripteurs morphologiques*

4. Protocole Expérimental Partagé (Règle d'Or)

La Règle d'Or du Protocole Partagé

- **Graine Aléatoire Universelle :** `SEED` = 42 commune.
- **Partitionnement Étanche :** 80 % Train ($N = 10\,888$) / 20 % Test ($N = 2\,723$), avec stratification stricte.
- **Validation Croisée 5-Plis :** `StratifiedKFold` sur le train pour tous les `GridSearchCV`.
- **Isolation du Test Set :** Évalué une seule et unique fois à la fin.

Vérification de la Stratification Train / Test

Variété	Corpus (%)	Train (%)	Test (%)
Dermason	26.05 %	26.05 %	26.04 %
Sira	19.37 %	19.37 %	19.35 %
Seker	14.89 %	14.89 %	14.91 %
Horoz	14.16 %	14.16 %	14.18 %
Cali	11.98 %	11.98 %	11.97 %
Barbunya	9.71 %	9.71 %	9.70 %
Bombay	3.84 %	3.84 %	3.86 %

Garantie Zéro Fuite (*Zero Data Leakage*)

Le `StandardScaler` est systématiquement encapsulé dans un `Pipeline` Scikit-Learn : appris (`fit`) **exclusivement sur les plis d'entraînement internes**.

Baseline Aléatoire Naïve

`DummyClassifier` (stratifié) plafonne à $F_1 = \mathbf{0.1472}$.

5. Expérience d'Ablation : Impact Vital du Centrage-Réduction

Résultats de l'Ablation (CV 5-plis Train)

Algorithme	Sans Scaling	Avec Scaling	Gain (pts)
SVM (Noyau RBF)	0.5983	**0.9343**	**+33.60**
KNN ($k = 9$)	0.7138	**0.9355**	**+22.17**
Régression Log.	0.7544	**0.9329**	**+17.85**
Forêt Aléatoire	0.9321	0.9321	**0.00**
Arbre CART	0.9194	0.9194	**0.00**

Verdict Expérimental

Le centrage-réduction est **obligatoire** pour SVM, KNN et Régression Logistique, mais strictement neutre pour les arbres.

Justification Mathématique

- **Modèles Métriques & Gradients :** Disparité d'échelle ($Area \approx 10^5$ vs $ShapeFactor \approx 10^{-3}$) : le calcul $\|\mathbf{x}_i - \mathbf{x}_j\|^2$ est écrasé par l'aire, annihilant le noyau gaussien.
- **Modèles Arborescents (Invariance) :** Coupures basées sur le critère de Gini : $x_j \leq s$. Toute transformation monotone $z = \frac{x-\mu}{\sigma}$ préserve l'ordre et laisse les partitions invariantes ($\Delta = 0.00$).

6. Modélisation & Optimisation des 5 Architectures

1. Régression Logistique (Softmax L_2)

$$P(y = k \mid \mathbf{x}) = \frac{\exp(\mathbf{w}_k^T \mathbf{x} + b_k)}{\sum_j \exp(\mathbf{w}_j^T \mathbf{x} + b_j)}.$$

Optimum : $C^* = 100$ (solveur L-BFGS). Convergence rapide et surface convexe bien conditionnée.

2. K-Plus Proches Voisins (KNN)

Agrégation locale non paramétrique.
Optimum : $k^* = 9$, distance euclidienne, pondération $w_i = 1/d$ (lève le flou décisionnel dense).

3. Arbre de Décision (CART)

Minimisation de l'impureté de Gini $I_G(t)$.
Optimum : $\texttt{max_depth}^* = 9$ (évite le sur-apprentissage précoce des arbres libres).

4. Forêt Aléatoire (Random Forest)

Ensemble de $B = 200$ arbres décorrélés par *bagging* et tirage aléatoire de $\sqrt{p} = 4$ variables par nœud.
Optimum : $n^* = 200$, $\texttt{max_depth}^* = 15$.
Réduit drastiquement la variance (+1.27 pt vs CART).

5. Support Vector Machines (SVM RBF)

Hyperplan à marge maximale avec variables souples :
$\min \frac{1}{2}\|\mathbf{w}\|^2 + C\sum \xi_i \quad \text{s.t.} \quad y_i(\mathbf{w}^T\phi(\mathbf{x}_i) + b) \geq 1 - \xi_i.$
Noyau gaussien $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2)$.
Optimum : $C^* = 5, \quad \gamma^* = 0.1$.
Courbe les frontières dans l'espace de Hilbert.

7. Grand Benchmark Comparatif sur le Test Set ($N_{\text{test}} = 2\,723$)

Synthèse Générale des Performances Comparatives

Rang / Modèle	Hyperparamètres Optimaux	F1 CV (Train)	Accuracy (%)	Précision	Rappel	F1 Macro	Inférence (ms)
1. **SVM (Noyau RBF)**	$C = 5, \gamma = 0.1$	**0.9388**	**92.47 %**	**0.9366**	**0.9362**	**0.9363**	15.2 ms
2. **Régression Logistique**	$C = 100$	0.9329	92.10 %	0.9333	0.9327	0.9329	**2.1 ms**
3. **Random Forest**	$n = 200, \texttt{depth} = 15$	0.9365	92.25 %	0.9325	0.9320	0.9321	28.4 ms
4. **KNN (Pondéré)**	$k = 9$, euclidien, distance	0.9382	92.18 %	0.9304	0.9298	0.9300	45.1 ms
5. **Arbre CART**	$\texttt{max_depth} = 9$	0.9194	90.56 %	0.9196	0.9193	0.9194	0.9 ms

1. Le Sacre du SVM RBF (Champion Absolu)

Domine sur l'ensemble des indicateurs ($F_1 = \mathbf{0.9363}$, Acc $= \mathbf{92.47}$ %). La marge maximale et la pénalisation $\|\mathbf{w}\|^2$ assurent la meilleure généralisation.

2. L'Efficience Record de la Régression Logistique

Talonne le champion à seulement 0.34 pt ($F_1 = 0.9329$) tout en exécutant l'inférence en **2.1 ms** (**7x plus rapide que SVM, 21x plus rapide que KNN**).

8. Analyse Désagrégée des Performances par Variété

Enseignements par Classe (Figure 3)

- **Sans-faute sur Bombay :** Score parfait de $F_1 = \mathbf{1.0000}$ pour les 5 modèles (0 faux positif, 0 faux négatif).
- **Stabilité sur Horoz & Seker :** $F_1 \geq 0.94$, captés par la compacité et l'élongation.
- **Cali & Barbunya :** Bien séparés ($F_1 \approx 0.93 - 0.94$).
- **Le Pivot Dermason / Sira :** $F_1 < 0.90$. C'est ici que le SVM RBF fait la différence ($+0.91$ pt vs LogReg).

Gain vs Baselines Factices

Nos modèles opèrent à plus de **6.3 fois au-dessus du hasard pur** (`DummyClassifier` à 0.1472).

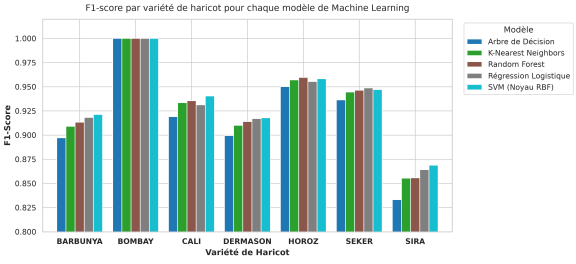


Figure 3 : *Comparaison des F1-scores par classe pour les 5 modèles*

9. Dissection des Confusions & Limite Bayesienne 2D

Bilan des 205 Erreurs du Champion (7.53 %)

- **46.8 % des erreurs = Dermason ↔ Sira :** 96 confusions mutuelles (52 Dermason pris pour Sira, 44 Sira pris pour Dermason).
- **11.7 % des erreurs = Barbunya ↔ Cali :** 24 grains mutuellement confondus (courbures proches).
- **Zéro pollution sur Bombay :** 0 confusion.

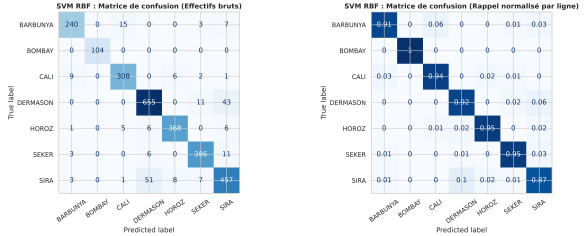


Figure 4 : *Matrice de confusion brute et normalisée (SVM RBF)*

Limite Bayesienne Intrinsèque 2D

Dans l'espace morphologique 2D, les distributions de Dermason et Sira **se chevauchent physiquement**. Aucun séparateur géométrique ne peut lever cette ambiguïté sans variable de couleur.

10. Synthèse des Réponses au Cahier des Charges & Perspectives

Réponses Concluantes aux 3 Questions Clés

1. **Meilleur modèle :** Le **SVM à noyau RBF** domine ($F_1 = \mathbf{0.9363}$), talonné par la Régression Logistique ($F_1 = 0.9329$) idéale pour les trieurs industriels haute cadence (2.1 ms).
2. **Classes les plus difficiles :** `DERMASON` ($F_1 = 0.8936$) et `SIRA` ($F_1 = 0.8778$).
3. **Rôle de la standardisation :** Indispensable pour SVM (+33.6 pts) et KNN (+22.2 pts), neutre sur les arbres.

Bilan Méthodologique

- Protocole sans fuite d'information validé.
- Étalonnage rigoureux par CV 5-plis stratifiée.
- 5 modèles pleinement opérationnels et documentés.

Perspectives Scientifiques

Intégration de descripteurs spectraux (couleur RGB / HSV, réflectance) ou de réseaux convolutifs (CNN) pour lever définitivement le verrou Dermason/Sira.

Merci pour votre attention !