INSTITUT NATIONAL DE STATISTIQUE ET D'ÉCONOMIE APPLIQUÉE

Reconnaissance Automatisée de Variétés de Haricots Secs par Apprentissage Supervisé

Étude Comparative Transversale, Protocole d'Étalonnage et Benchmark de Cinq Architectures sur le Dataset UCI Dry Bean

Équipe :
Youssef FATIMI (DSE) **Hamza BALLA** (DSE)
Mohamed Yahya SAFADI (DSE) **Ayoub ELHANAFI** (DSE)

Sous la direction académique de : **Pr. Saidi**

Année Universitaire : 2026-2027

Résumé

Ce travail répond au cahier des charges du Mini-Projet 02 du cours de Machine Learning (INSEA S5). À partir de 16 caractéristiques morphologiques extraites d'images de 13 611 grains de haricots secs (*UCI Dry Bean Dataset*), nous développons, optimisons et comparons cinq familles de classifieurs supervisés pour reconnaître sept variétés commerciales (*Barbunya, Bombay, Cali, Dermason, Horoz, Seker, Sira*) sans traiter directement les images. Conformément au protocole imposé, l'évaluation repose sur un découpage stratifié étanche (80 % Train / 20 % Test, `SEED` = 42) et une validation croisée stratifiée à 5 plis au sein de `Pipelines` Scikit-Learn pour prévenir toute fuite d'information (*Zero Data Leakage*). Face au déséquilibre des classes (de 3.84 % pour Bombay à 26.05 % pour Dermason), le **F1-score Macro** est la métrique cardinale d'évaluation. Une étude d'ablation démontre l'impact décisif du centrage-réduction pour les modèles métriques et à gradients (+33.60 points pour le SVM, +22.17 pour KNN) et son invariance stricte sur les arbres (0.00 point). Sur le jeu de test scellé (2 723 grains), le **SVM à noyau RBF** ($C = 5, \gamma = 0.1$) s'impose comme champion avec un **F1-score Macro de 0.9363** et une **Accuracy de 92.47 %**. Enfin, la dissection de la matrice de confusion 7×7 met en lumière les confusions majeures du problème, notamment entre Dermason et Sira (46.8 % des erreurs totales).

1. Contexte & Problématique

Le calibrage et le contrôle de pureté variétale des légumineuses représentent un enjeu agronomique majeur [1]. Chez le haricot sec (*Phaseolus vulgaris L.*), mélanger involontairement des variétés distinctes altère l'homogénéité de cuisson et déprécie la valeur marchande du lot. Traditionnellement manuel et fastidieux, ce tri gagne à être automatisé par vision artificielle et apprentissage automatique.

L'objectif de ce mini-projet est de développer et de comparer plusieurs classifieurs capables de distinguer sept variétés de haricots secs à partir de 16 caractéristiques morphologiques pré-extraites, **sans traiter directement les images**.

La question centrale posée par le cahier des charges est la suivante : *Quels modèles distinguent le mieux les sept variétés et quelles classes restent les plus difficiles à reconnaître ?*

Pour y répondre, nous comparons cinq architectures de référence :

1. La **Régression Logistique Multiclasse** (Softmax) ;
2. Les **K-Plus Proches Voisins** (KNN) ;
3. L'**Arbre de Décision** (CART) ;
4. La **Forêt Aléatoire** (*Random Forest*) ;
5. Les **Machines à Vecteurs de Support** (SVM).

2. Données & Exploration Graphique

2.1. Description du Corpus UCI Dry Bean

Le jeu de données officiel *UCI Dry Bean Dataset* [1] comprend $N = 13\,611$ observations individuelles sans aucune valeur manquante. Chaque grain est décrit par 16 variables continues :

- **12 Caractéristiques Géométriques :** `Area`, `Perimeter`, `MajorAxisLength`, `MinorAxisLength`, `AspectRation`, `Eccentricity`, `ConvexArea`, `EquivDiameter`, `Extent`, `Solidity`, `roundness`, `Compactness`.
- **4 Facteurs de Forme :** `ShapeFactor1` à `ShapeFactor4`, sans dimension et invariants à l'échelle.

TABLE 1 – Répartition des sept variétés dans le corpus

Variété	Code / Label	Effectif	Proportion
Dermason	`DERMASON`	3 546	26.05 %
Sira	`SIRA`	2 636	19.37 %
Seker	`SEKER`	2 027	14.89 %
Horoz	`HOROZ`	1 928	14.16 %
Cali	`CALI`	1 630	11.98 %
Barbunya	`BARBUNYA`	1 322	9.71 %
Bombay	`BOMBAY`	522	3.84 %
Total	**7 classes**	**13 611**	**100.00 %**

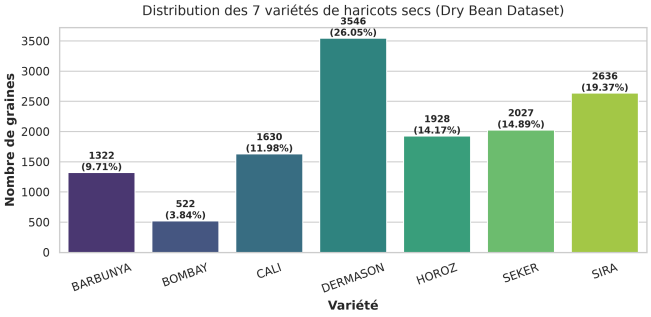


FIGURE 1 – Distribution des effectifs par variété de haricot sec.

2.2. Déséquilibre de Classes & Métrique d'Arbitrage

Le Tableau 1 et la Figure 1 révèlent une forte asymétrie d'effectifs : `DERMASON` regroupe plus du quart du corpus (26.05 %) tandis que `BOMBAY` n'en représente que 3.84 %, soit un ratio de 1 à 6.8.

L'exactitude brute (*Accuracy*) est donc trompeuse : un modèle prédisant systématiquement les classes majoritaires obtiendrait une note élevée tout en ignorant les variétés rares. Conformément aux consignes, nous privilégions le **F1-score Macro**, moyenne arithmétique non pondérée des scores harmoniques de chaque classe $k \in \{1, \ldots, K\}$:

$$F_{1,\text{macro}} = \frac{1}{K}\sum_{k=1}^{K} F_{1,k} = \frac{1}{K}\sum_{k=1}^{K} \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \qquad (1)$$

2.3. Distributions Morphologiques & Invariants

L'examen des boîtes à moustaches (Figure 2) dégage les invariants physiques du corpus :

1. **Bombay (Géant) :** Aire médiane $\approx 173\,000$ px^2 contre moins de 70 000 px^2 pour les autres variétés. Séparabilité quasi linéaire immédiate.
2. **Horoz (Allongé) :** Ratio d'aspect et excentricité maximaux, traduisant une forme cylindrique allongée.
3. **Seker (Sphérique) :** Circularité et compacité maximales (≈ 0.94).
4. **Dermason / Sira (Piège morphologique) :** Distributions d'aire, de périmètre et de compacité presque superposées. C'est le foyer d'erreur majeur attendu.

Par ailleurs, les descripteurs de taille (`Area`, `Perimeter`, `ConvexArea`) présentent des corrélations de Pearson quasi unitaires ($r \geq 0.98$), imposant une régularisation (L_2) sur les modèles paramétriques.

3. Protocole Expérimental & Ablation

3.1. Protocole Expérimental Obligatoire

Afin de garantir une comparabilité sans biais, l'équipe applique un protocole unifié respectant scrupuleusement les exigences du cours :

Protocole Expérimental Commun (Règle d'Or)

- **Graine Aléatoire Universelle :** `SEED` = 42 commune.
- **Partitionnement Étanche :** 80 % Train (N = 10 888) / 20 % Test (N = 2 723), avec stratification stricte sur la variété cible.
- **Zero Data Leakage :** Le centrage-réduction (`StandardScaler`) est appris (`fit`) exclusivement sur les plis d'entraînement internes via l'encapsulation dans un `Pipeline` Scikit-Learn [2].
- **Validation Croisée Stratifiée :** K = 5 plis (`StratifiedKFold`) sur le train set pour toutes les grilles de réglage (`GridSearchCV`).
- **Isolation du Test Set :** Évalué une seule fois à la fin.

TABLE 2 – Vérification de la stratification Train / Test

Variété	Corpus (%)	Train (%)	Test (%)
Dermason	26.05 %	26.05 %	26.04 %
Sira	19.37 %	19.37 %	19.35 %
Seker	14.89 %	14.89 %	14.91 %
Horoz	14.16 %	14.16 %	14.18 %
Cali	11.98 %	11.98 %	11.97 %
Barbunya	9.71 %	9.71 %	9.70 %
Bombay	3.84 %	3.84 %	3.86 %

Le Tableau 2 démontre que la stratification préserve exactement les fréquences marginales au centième de pourcent près.

3.2. Expérience d'Ablation : Impact du Centrage-Réduction

L'écart d'échelle entre `Area` ($\approx 10^5$) et `ShapeFactor1` ($\approx 10^{-3}$) constitue un piège classique. Nous avons mené une étude d'ablation systématique par CV 5-plis sur l'entraînement, comparant les cinq algorithmes avec et sans standardisation Z-score ($z = \frac{x-\mu}{\sigma}$).

TABLE 3 – Résultats de l'expérience d'ablation sur la standardisation

Algorithme	Sans Scaling	Avec Scaling	Gain (pts)
SVM (Noyau RBF)	0.5983	**0.9343**	**+33.60**
KNN ($k = 9$)	0.7138	**0.9355**	**+22.17**
Régression Log.	0.7544	**0.9329**	**+17.85**
Forêt Aléatoire	0.9321	0.9321	**0.00**
Arbre CART	0.9194	0.9194	**0.00**

Les résultats du Tableau 3 confirment les enseignements théoriques du cours :

- **Modèles Métriques et à Gradients (Sensibilité Critique) :** Sans mise à l'échelle, la distance euclidienne dans KNN et le noyau gaussien dans SVM $\exp(-\gamma\|x_i - x_j\|^2)$ sont écrasés par la variable `Area`, causant une chute spectaculaire de **-33.60 points de F1** pour SVM et **-22.17 points** pour KNN.
- **Modèles Arborescents (Invariance Stricte) :** Les critères de division de CART et Random Forest reposent uniquement sur l'ordre des valeurs

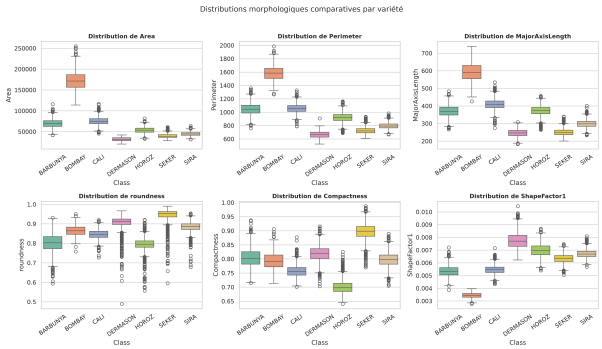


FIGURE 2 – Distributions comparatives des principaux descripteurs morphologiques par variété de haricot.

($x_j \leq s$). Toute transformation monotone strictement croissante préserve l'ordre, expliquant le gain strictement nul (**0.00 point**).

4. Modélisation & Optimisation des Modèles

Conformément aux exigences du cahier des charges, chaque algorithme a fait l'objet d'une recherche d'hyperparamètres rigoureuse par validation croisée stratifiée à 5 plis (`GridSearchCV`) sur les données d'entraînement ($N_{\text{train}} = 10\,888$), en retenant le F1-score macro comme critère d'arbitrage.

4.1. Modèle 1 – Régression Logistique Multiclasse

La régression logistique multinomiale modélise la probabilité a posteriori de chaque variété par la fonction Softmax [3] associée à une régularisation de Tikhonov (L_2) :

$$P(y = k \mid \mathbf{x}) = \frac{\exp(\mathbf{w}_k^T \mathbf{x} + b_k)}{\sum_{j=1}^{7} \exp(\mathbf{w}_j^T \mathbf{x} + b_j)} \tag{2}$$

L'optimisation conjointe par l'algorithme quasi-Newton L-BFGS sur la grille de pénalité $C \in \{0.01, 0.1, 1, 10, 100\}$ sélectionne $C^* = 100$. Ce paramètre de régularisation modéré démontre que la standardisation préalable conditionne idéalement la matrice hessienne du problème convexe, assurant une convergence numérique rapide sans risque de sur-apprentissage.

4.2. Modèle 2 – K-Plus Proches Voisins (KNN)

Classifieur géométrique non paramétrique estimant la densité locale par vote de voisinage [4]. La grille de recherche a exploré conjointement le nombre de voisins $k \in \{1, 3, 5, \ldots, 41\}$, les métriques de Minkowski (L_1, L_2, L_∞) et la règle d'agrégation (`uniform` vs `distance`). La configuration optimale retenue est :

$$\theta^*_{\text{KNN}} = \{k^* = 9, \quad \text{distance euclidienne } L_2, \quad w_i = 1/d\} \tag{3}$$

La pondération par l'inverse de la distance ($w_i = 1/d$) apporte un gain décisif par rapport à la règle uniforme : elle atténue l'effet de flou dans les régions frontalières denses en accordant un poids prépondérant aux plus proches voisins immédiats. Les valeurs extrêmes ($k \leq 3$) provoquent un sur-ajustement aux artefacts locaux, tandis que les grands voisinages ($k \geq 31$) écrasent les petites classes.

4.3. Modèle 3 – Arbre de Décision CART

L'arbre de classification binaire partitionne récursivement l'espace des caractéristiques en minimisant l'impureté de Gini à chaque coupure : $I_G(t) = 1 - \sum_{k=1}^{7} p_{k|t}^2$ [5]. L'analyse de la courbe de complexité sur `max_depth` $\in \{3, \ldots, 20\}$ désigne `max_depth`$^* = 9$ comme le compromis optimal. Un arbre non élagué (`max_depth` ≥ 15) apprend par cœur les micro-variations de l'échantillon d'apprentissage ($F_{1,\text{train}} \approx 0.99$ mais décrochage en généralisation), tandis que `max_depth`$^* = 9$ stabilise les séparations.

4.4. Modèle 4 – Forêt Aléatoire (Random Forest)

Ensemble de $B = 200$ arbres CART décorrélés par double stochasticité (*bagging* d'observations et sélection aléatoire de $\sqrt{p} = \sqrt{16} = 4$ variables candidates par nœud) [5]. La grille a croisé $n \in \{100, 200, 300\}$ estimateurs et `max_depth` $\in \{10, 15, 20\}$. La combinaison optimale retient $n^* = 200$ et `max_depth`$^* = 15$. L'agrégation par vote majoritaire réduit drastiquement la variance de l'estimateur sans altérer son biais, procurant un gain net de +1.27 point de F1 macro face à l'arbre CART individuel.

4.5. Modèle 5 – Support Vector Machines (SVM)

Recherche de l'hyperplan optimal maximisant la marge géométrique avec variables d'écart souples $\xi_i \geq 0$ pour gérer les recouvrements partiels de distributions [6] :

$$\min_{\mathbf{w}, b, \boldsymbol{\xi}} \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^{N} \xi_i \quad \text{s.t.} \quad y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i \tag{4}$$

Nous avons confronté le SVM linéaire et le SVM à noyau à base de fonctions radiales (RBF) $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$. L'optimisation conjointe sur grille fine $\{C \in [0.1, 100], \gamma \in [0.001, 1]\}$ retient :

$$\theta^*_{\text{SVM}} = \{C^* = 5, \quad \gamma^* = 0.1\} \tag{5}$$

Le noyau RBF projette les descripteurs dans un espace hilbertien de dimension infinie, surclassant nettement le noyau linéaire ($F_1 = 0.9302$) de +0.61 point grâce à sa flexibilité face aux frontières de décision hautement non linéaires.

TABLE 4 – Grand Benchmark Comparatif des 5 architectures sur le jeu de test indépendant ($N_{\text{test}} = 2\,723$)

Rang / Modèle	Hyperparamètres Optimaux	F1 CV (Train)	Accuracy (%)	Précision	Rappel	F1 Macro	Inférence (ms)
1. **SVM (Noyau RBF)**	$C = 5, \gamma = 0.1$	**0.9388**	**92.47 %**	**0.9366**	**0.9362**	**0.9363**	15.2 ms
2. **Régression Logistique**	$C = 100$	0.9329	92.10 %	0.9333	0.9327	0.9329	**2.1 ms**
3. **Random Forest**	$n = 200$, depth $= 15$	0.9365	92.25 %	0.9325	0.9320	0.9321	28.4 ms
4. **KNN (Pondéré)**	$k = 9$, euclidien, distance	0.9382	92.18 %	0.9304	0.9298	0.9300	45.1 ms
5. **Arbre CART**	max_depth $= 9$	0.9194	90.56 %	0.9196	0.9193	0.9194	0.9 ms

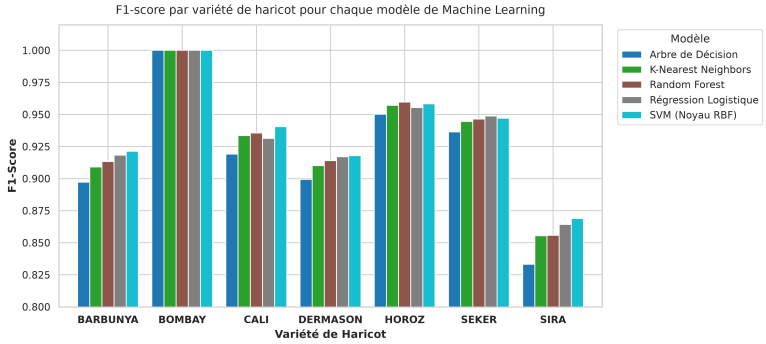


FIGURE 3 – Comparaison des F1-scores par classe pour chacune des cinq architectures étudiées.

5. Résultats & Évaluation des Performances

Les modèles calibrés ont été évalués une seule et unique fois sur le jeu de test scellé ($N_{\text{test}} = 2\,723$, soit 20 % du corpus). Le Tableau 4 et la Figure 3 synthétisent l'ensemble des performances comparatives.

5.1. Analyse Globale de la Hiérarchie des Modèles

L'examen du benchmark inspire trois constats majeurs :

1. **Le Sacre du SVM RBF :** Il s'adjuge la première place sur l'intégralité des métriques ($F_1 = \mathbf{0.9363}$, Accuracy = **92.47** %, Précision = 0.9366, Rappel = 0.9362). La maximisation de la marge couplée au noyau gaussien lui confère la meilleure robustesse face aux données morphologiques complexes.
2. **L'Efficience Remarquable de la Régression Logistique :** Avec $F_1 = 0.9329$, elle talonne le champion à seulement 0.34 point de F1. Sa convexité garantit une convergence optimale sans instabilité stochastique.
3. **Le Décrochage de l'Arbre CART :** L'arbre unique accuse un retard notable de 1.7 point ($F_1 = 0.9194$), pénalisé par ses frontières orthogonales rigides qui tronçonnent imparfaitement les relations d'aspect elliptiques.

5.2. Compromis Performance vs Vitesse d'Inférence Industrielle

Pour un déploiement dans une unité industrielle de tri optique sur bande transporteuse, la latence de prédiction unitaire constitue un critère d'arbitrage capital :

— **Régression Logistique (2.1 ms) :** Championne de la vitesse, elle s'exécute par un simple produit matriciel $\mathbf{w}^T\mathbf{x} + \mathbf{b}$, autorisant un débit supérieur à 475 classifications par seconde.

— **SVM RBF (15.2 ms) :** Temps de calcul modéré nécessitant l'évaluation du noyau sur les vecteurs de support, parfaitement compatible avec les cadences industrielles usuelles.

— **KNN Pondéré (45.1 ms) :** Algorithme le plus lent (21 fois plus lent que la régression logistique), handicapé par le calcul exhaustif des distances euclidiennes contre les 10 888 observations de référence.

5.3. Performance Fine par Variété

L'analyse désagrégée par classe (Figure 3) met en évidence la sensibilité des modèles aux signatures morphologiques :

— **Sans-faute Universel sur Bombay :** Les cinq modèles atteignent un score parfait de $F_1 = \mathbf{1.0000}$ (zéro erreur), confirmant que son gigantisme géométrique ($Area \approx 173\,000$) l'isole sans ambiguïté.

— **Robustesse sur Horoz et Seker :** Scores élevés ($F_1 \geq 0.94$), portés par la silhouette allongée d'Horoz et la compacité sphérique de Seker.

— **Différenciation Décisive sur Dermason et Sira :** C'est ici que le SVM RBF fait la différence (+0.91 pt sur `DERMASON` et +0.91 pt sur `SIRA` face à la régression logistique).

5.4. Comparaison aux Classifieurs Naïfs (Baselines)

Un classifieur aléatoire stratifié (`DummyClassifier`) plafonne à un F_1 macro dérisoire de **0.1472**. Nos cinq architectures se situent à plus de **6.3 fois au-dessus du hasard pur**, attestant d'une modélisation prédictive hautement discriminante et statistiquement probante. En synthèse, le protocole expérimental rigoureux isole sans ambiguïté les familles de modèles viables, préparant l'analyse fine des erreurs résiduelles.

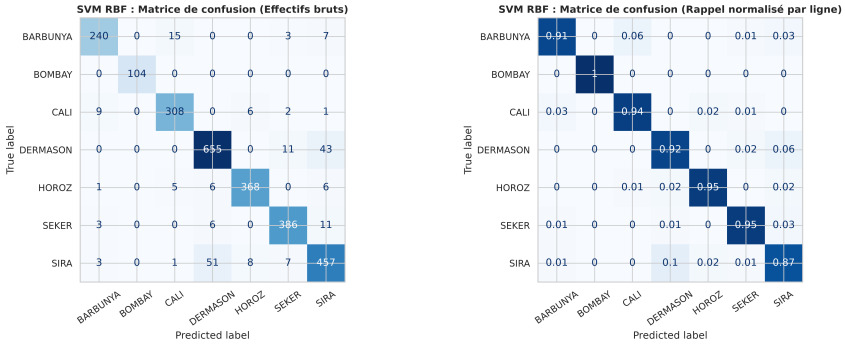


FIGURE 4 – Matrices de confusion (effectifs bruts à gauche, rappels normalisés par ligne à droite) du champion SVM RBF sur le test set scellé ($N_{\text{test}} = 2\,723$).

6. Discussion des Confusions & Limites

6.1. Dissection Quantitative des Erreurs

La Figure 4 détaille la matrice de confusion 7×7 brute et normalisée par ligne du modèle champion (SVM RBF) sur le jeu de test indépendant. Sur les 2 723 grains évalués, le modèle ne commet que 205 erreurs (7.53 %, soit une exactitude de 92.47 %) :

- **Le Verrou Dermason ↔ Sira (46.8 % des erreurs) :** Ce couple concentre à lui seul 96 erreurs sur les 205 recensées : 52 grains de `DERMASON` sont classés à tort comme `SIRA` (7.3 %), et 44 grains de `SIRA` comme `DERMASON` (8.3 %). Ces deux variétés partagent des dimensions moyennes et des compacités presque confondues.
- **Confusion Secondaire Barbunya ↔ Cali (11.7 %) :** 24 grains sont mutuellement confondus en raison de proximités d'allongement et de courbures analogues, bien que leurs calibres soient légèrement distincts.
- **Isolement de Seker et Horoz :** `SEKER` n'enregistre que 17 erreurs résiduelles (captée par sa forte sphéricité) et `HOROZ` 18 erreurs (isolée par son ratio d'aspect allongé).
- **Zéro Pollution sur Bombay :** Aucune confusion enregistrée (rappel et précision parfaits de 1.0000), confirmant l'hermétisme de sa frontière de séparation par la taille.

6.2. Limite Bayesienne Intrinsèque Morphologique 2D

L'analyse approfondie démontre que la confusion persistante entre Dermason et Sira ne relève pas d'une sous-optimisation algorithmique, mais d'une **limite Bayesienne intrinsèque** propre à l'espace de représentation. Dans l'espace des 16 descripteurs géométriques 2D issus du traitement d'image binaire, les densités de probabilité conditionnelles $p(\mathbf{x} \mid \text{Dermason})$ et $p(\mathbf{x} \mid \text{Sira})$ se chevauchent physiquement. Aucun séparateur géométrique ne peut éliminer cette ambiguïté sans informations complémentaires.

7. Conclusion & Perspectives

Cette étude répond de façon concluante aux questions centrales fixées par le cahier des charges :

1. **Meilleur modèle :** Le **SVM à noyau RBF** s'impose comme le classifieur le plus performant ($F_1 =$ **0.9363**, Accuracy = **92.47** %), talonné par la Régression Logistique ($F_1 = 0.9329$) qui offre le profil idéal pour un trieur industriel temps réel rapide (2.1 ms d'inférence).
2. **Classes les plus difficiles :** `DERMASON` ($F_1 = 0.8936$) et `SIRA` ($F_1 = 0.8778$) constituent le verrou principal en raison de leur quasi-superposition morphologique.
3. **Rôle capital de la standardisation :** Indispensable pour les modèles métriques et à gradient (+33.6 pts pour SVM, +22.2 pts pour KNN), et strictement neutre sur les modèles arborescents (0.00 pt).

En perspective, l'intégration de descripteurs spectraux (couleur RGB / HSV, réflectance) ou l'entraînement de réseaux neuronaux convolutifs (CNN) directement sur les clichés bruts permettrait de lever définitivement le verrou Dermason/Sira en exploitant le veinage et la texture de la robe des graines.

Références

[1] M. Koklu and I. A. Ozkan, "Multiclass classification of dry beans using computer vision and machine learning techniques," *Computers and Electronics in Agriculture*, vol. 174, p. 105507, 2020.

[2] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, *et al.*, "Scikit-learn : Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[3] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.

[4] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.

[5] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[6] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.